Comparing the functional domain of linguistic elements across languages: ParaViz and the place of R

Ruprecht von Waldenfels, ruprecht.waldenfels@gmail.com

Instute of the Polish Language, Polish Academy of Sciences ruprecht.waldenfels@gmail.com

Spotkanie miłośników R w Krakowie - May 13th 2015

(IJP PAN) ParaViz 1 /

- Comparing functional domains on the basis of a parallel corpus
 - ParaSol: A Parallel Corpus of Slavic and other Languages
- Operationalization and query
 - An example: cognate prepositions
 - Operationalization
 - Evaluation: corpus examples
- Visualisation
 - Visualising single classes
 - Clustering Classes
 - Clustering language-specific types
- Summarization
- 6 A web application and partial implementation in R

- Comparing functional domains on the basis of a parallel corpus
 - ParaSol: A Parallel Corpus of Slavic and other Languages
- Operationalization and query
 - An example: cognate prepositions
 - Operationalization
 - Evaluation: corpus examples
- 3 Visualisation
 - Visualising single classes
 - Clustering Classes
 - Clustering language-specific types
- Summarization
- 6 A web application and partial implementation in R


Usage-based approach

 parallel corpora as a tool to compare functional domains of comparable elements bottom-up, starting from actual usage

(IJP PAN) ParaViz 4 / 49

Usage-based approach

 parallel corpora as a tool to compare functional domains of comparable elements bottom-up, starting from actual usage



- Comparing functional domains on the basis of a parallel corpus
 - ParaSol: A Parallel Corpus of Slavic and other Languages
- Operationalization and query
 - An example: cognate prepositions
 - Operationalization
 - Evaluation: corpus examples
- 3 Visualisation
 - Visualising single classes
 - Clustering Classes
 - Clustering language-specific types
- Summarization
- 6 A web application and partial implementation in R



ParaSol: A Parallel Corpus of Slavic and other languages



Overview

The ParaSol, formerly known as the Regensburg Parallel Corpus (RPC), is a parallel aligned corpus of translated and original belletristic texts in Slavic and some other languages, developed jointly by Ruprecht von Waldenfels and Roland Meyer, at the Institute of Slavic Languages and Literatures, University of Bern and the Institute of Slavistics, Regensburg University, respectively. We gratefully acknowledge support by research assistants and server hosting at Regensburg University.

The corpus is in the process of being reorganized. Many new texts have been added, and the corpus has been rechristened. Hopefully, there will be a full relaunch with many improvement towards the end of 2009.

The corpus is "work in progress" and open in terms of languages as well as texts. We ask interested linguists using this resource to contribute by adding new texts or languages.

Public access to the corpus is provided via a public web interface (beta stage).

Here's a short introduction in German and in English on how to use it, as well as the list of texts.

In order to register for use, please fill in this form.

A short outline of the corpus

- ParaSol focuses on
 - o post-war belletristic texts (but also contains some legal and journalistic texts)
 - Slavic languages, but not exclusively: English and German are also included, and we hope to add more languages as the corpus grows.
 - o texts that are translated into many Slavic languages, so that subsequent addition of further translations of can build on already included translations
 - for more information, see the list of texts and languages currently included in the corpus.



ParaSol: A Parallel Corpus of Slavic and other languages



Overview

The ParaSol, formerly known as the Regensburg Parallel Corpus (RPC), is a parallel aligned corpus of translated and original belietristic texts in Slavic and some other languages, developed jointly by Ruprecht von Waldenfels and Roland Mever, at the Institute of Slavic Languages and Literatures, University of Bern and the Institute of Slavistics, Regensburg University, respectively. We gratefully acknowledge support by research assistants and server hosting at Regensburg University.

The corpus is in the process of being reorganized. Many new texts have been added, and the corpus has been rechristened. Hopefully, there will be a full relaunch with many improvement towards the end of 2009.



- ParaSol focuses on
 - o post-war belletristic texts (but also contains some legal and journalistic texts)
 - o Slavic languages, but not exclusively: English and German are also included, and we hope to add more languages as the corpus grows.
 - o texts that are translated into many Slavic languages, so that subsequent addition of further translations of can build on already included translations
 - for more information, see the list of texts and languages currently included in the corpus.

Advanced querying

Primary language:

Slavonic

PRC PSPA PIA PIL

On this page, first specify one primary and several other languages and then choose subcorpora (texts) and queries. You need to specify a query on the primary language.

You may also define queries on the other languages, which apply in addition to the query on the primary language.

For example, choosing pl (Polish) as primary and de (German), ru (Russian) and bx (BCS) as additional languages, a query on pl [word="nigdy"] will "nigdy" as well as all their translations in German, Russian and Bosnian/Croatian/Serbian.

An additional query over BCS [word="nikad"] will constrain the search results to (a) include only those segments that contain "nigdy" in the Polish ve Additional queries may be negated: Using ![word="nikad"] as an additional query will result in all segments that (a) contain "nigdy" in the Polish and

Romance

OFD OFC

Baltic

@ LV

Others

Only te	extes ava	DEA	A PT RO	[tag="Vmm.*" & ler	емта ="."писать"]
Only te	extes av	DEA	A PT RO n all languages Tua Russian	[tag="Vmm.*" & ler	етта =".*писать"]
Only te	extes ava	DEA	A PT RO	[tag="Vmm.*" & ler	emma =".*писать"]
Only te	extes ava	DEA	A PT RO		
	PL BY		CZ US UK DE	CZ WUS WUK DE PT	PL BY DEA RO
SL V	SL SK	SL VSK RUA			SL WSK WRUA EN IT LT

Germanic

O NII

✓ lempowgwiazd	V						V				V		01	
✓ sueskindparfuem	V	7		V	7	7	7		V		V		Slovene	
lemwizjalokalna							7				V		Bulgarian	
☑ lemglospana				V		V	V				V		0	
✓ endemomo							V				V		Croatian	
✓ potter4							V				V		Macedonian	
✓ lemastronauci						7	V				V		Orabian	
bulgakovmaster	V	7	V	V	7	7	7	7	V		V		Serbian	
✓ ostrovskijstal	V	7	7	V	7	7	V		V	V	V		Slovak	
✓ pelevincapaev	V						7				V		Durates -	
✓ pavichazar	V		V	V			V		V		V		Russian a	
✓ lempamwannie						V	V				V		Polish a	
strugpiknik	V					V	V		V		V		Hanna Cashina	
☑ lemfiasko				V		V	V				V		Upper Sorbian	
gombrowiczferdyduke							7				V		Czech	
Viemeolarie	7	7		7		7	7				7	7		

34794 Ему приходится читать мне речь три - четыре раза своим благозвучным баритоном , пока она не приобретет подлинную убедительность .

42334 Здесь ежедневно предлагают на выбор три меню , внизу в баре сидят жиголо , которые готовы потанцевать со мной, но я больше не танцую.

61523 точно зная , что , потребовав сто процентов , получит только сорок два , он , когда ему дают сорок три с A on by mohol vytvorit' kompromis , ved' presne viem , ked' požaduji половиной , трубит победу , ибо не подовревает , что ему с легкостью дали бы и сорок восемь и что основания daiú 43 1 // 2 a on triumfuie , lebo nevie , že by mu boli dali ai 48 , лля торжества имеет не он , а другая сторона .

Musí mi to nahlas prečítať tri , štvri razv , aby jeho plnozvučný barvt

Tri razy denne sa ponúka jedlo , dolu v bare sedia gigolovia , a keby netancujem - a večer prechádzajú z lesa cez lúku srnčjatka .

для горжества имеет не он , а друга	зя сторона.		ulumlovat , oni .		
38 hits in corpus bulgakovmaster.					h.
2550 - Взять бы этого Канта , да за такие доказательства года на три в Соловки !	- » Tega Kanta bi bilo treba za take dokaze poslati za tri leta na	sr - Tog Kanta bi za te i takve dokaze trebalo najuriti na jedno tri godine u Solovke !	bg — Тоя Кант за подобни доказателства ноже ли да го приберат за две - три годинки в Соловки!	mk - Да го земеме тој Кант и за таквите докази да го испратиме на едно три години во Соловки!	hr - Trebalo bi ti za takve doka godine u Solo
13674 За ним по три в ряд полетели всадники в туче пыли , запрытали кончики легких бакибуковак лик, инию прокуратора понеслись казавшиеся особо счутлыми под бельми тюрбанами лица с весело оскаленными , сверкающими зубами .	prahu , konice njihovih lahkih bambusovih sulic so poskakovale , in mimo prokuratorja so se podili obrazi , ki so se zdeli še	Za njim - po tri u redu - projuriše konjanici u oblaku prašne , promakoše vrhovi bambusovih kopalja , kraj prokuratora proleteše zrazito tamna lica pod belim turbanima , veselo iskeženih belih zuba .	- Зад него по трина в редица полетяха сред облак прах конниците, заподскачаха връхчетата на леките бамбухови пики, покрай прокуратора се понесоха лица с весело отолени блестящи зъби, под белите чалии тези лица изглеждаха още по - муртави.	, со весело светната соголени	Za njim su u c trojica u redu konjanici , pos laganih bambu mimo prokura lica koja su se turbanima čini tamnoputa , s blistavim zubir
17076 Пропустив нимо себя все три вагона , кот вскочил на заднюю дугу последнего , лапой вцепился в какую - то кишку , въюхдацую из стенки , и укатил , сэкононив , таким образом , гривенник .	, skočil na zadnji konec zadnjega , zasadil kremplje v neko cev , ki je štrlela iz stene ,	Propustivši najpre sva tri vagona , on skoči na papučicu poslednjeg , uhvativši se šapom za nekalkvo crevo koje je virilo iz tramvaja , i odveze se , uštedevši tako deset kopejki .	Той изчака да отнинат и трите вагона и скочи на задния буфер на последния , вкопчи се в някакъв маркуч , който се подаваше от транвая , и офейка , слестил по този начин десет копейки .	Пролуштајќи ги крај себе трите вагони , начорот скокна на задната платфорна на последниот , се закачи за некое си црево што се подаваше од ѕидот и си замина , заштедувајќи си го на тој начин гривеникот тој начин гривеникот тој начин гривеникот .	Propustivši kra vagona , mača stražnju željez posljednjem v uhvatio za nek njega virila , i uštedjevši na s kopjejaka .
20173 Дач всего двадцать две , и строится еще только семь , а нас в " МАССОЛИТе " <mark>три</mark> тысячи .	postavljajo jih le še sedem , nas	Vikendica ima samo dvadeset i dve , gradi se još sedam , a nas je u MASSOLIT - u tri hiljade .	седем нови , а в МАССОЛИТ	Има се на се дваесет и две вили и се градат уште само седум , а во МАССОЛИТ не има три илјади .	Ljetnikovaca ir i dva , a gradi sedam , a nas tri tisuće .
<mark>23478</mark> - Мне двадцать т <mark>ри</mark> года , - возбужденно заговорил Иван , - и я подам жалобу на вас всех .		- Imam dvadeset i tri godine - uzbuđeno poče Ivan - i uložiću žalbu protivu svih vas .	— На двайсет и три години съм — възбудено заговори Иван — и ще напиша оплакване срещу всички вас .	- Имам дваесет и три години ,- возбудено почна Иван ,- и јас ќе ве тужам сите вас .	– Meni su dva uzbuđeno je p žalit ću se na :
26699 Анна Францевна де Фужере , пятидесятилетняя почтенная и очень деловая дама , три комнаты из пяти сдавала жильцам :	petih oddajala najemnikom : nekomu , ki se je menda pisal	Ana Francevna de Fužere , pedesetogodišnja , poštovanja dostojna i uza sve to veoma poslovna dama , tri od pet soba iznajmljivala je stanarima :	Ана Францевна дьо Фужере , петдесетгодишна почтена и много делова дама , даваше три от общо петте си стаи под наем на някакъв човек , който се казваше , струва ми се ,	Ана Францевна де Фужере , педесеттодишна дана , почитувана и многу деловна , трите соби от петте ги издаваше на потстанари :	Ana Francevna pedesetogodiš poslovna dama tri od pet soba

State of corpus

LNG	in full	tokens	lemmas	tags
BG	Bulgarian	2 002 697	43 280	у
BY	Belarusian	482 467	24 131	У
CZ	Czech	1 629 868	47 166	у
DA	Danish	100 448	0	n
DE	German	2 006 781	64 112	у
EE	Estonian	287 948	23 031	у
EL	Greek	600 594	40 141	у
EN	English	814 289	19 886	У
EO	Esperanto	152 660	0	n
ES	Spanish	476 301	21 414	У
FI	Finnish	174 204	0	n
FR	French	448 612	10 870	У
HR	Croatian	899 466	43 263	У
HU	Hungarian	146 505	0	n
HY	Armenian	240 815	7 873	У
IT	Italian	478 315	19 472	у
LT	Lithuanian	280 675	8 001	у
LV	Latvian	147 906	0	n
MK	Macedonian	1 045 873	43 646	у
NL	Dutch	728 061	4 836	У
NO	Norwegian	334 948	13 788	у
PL	Polish	3 396 673	66 492	у
PT	Portuguese	380 659	10 961	У
RO	Romanian	398 088	15 164	у
RU	Russian	3 637 357	78 997	У
SK	Slovak	1 457 925	51 010	у
SL	Slovene	1 132 839	36 229	у
SR	Serbian	1 324 929	42 602	у
SV	Swedish	314 759	0	n
UK	Ukrainian	1 017 054	33 562	У
US	Upper Sorbian	73 266	0	n

32 languages, >400 pairs, 25 mio token In all major Slavic languages:

- Michail Bulgakov: Master i Margarita
- Stanisław Lem: Solaris
- Umberto Eco: Il nome della rosa
- Patrick Süskind: Das Parfüm
- Nikolaj Ostrovskij: Kak zakaljalos' stal'
- Joanne K. Rowling: Harry Potter and the Sorcerer's Stone
- Ivo Andrić: Na Drini ćuprija
- Milan Kundera: Nesnesitelná lehkost bytí

http://www.parasolcorpus.org

- Comparing functional domains on the basis of a parallel corpus
 - ParaSol: A Parallel Corpus of Slavic and other Languages
- Operationalization and query
 - An example: cognate prepositions
 - Operationalization
 - Evaluation: corpus examples
- Wisualisation
 - Visualising single classes
 - Clustering Classes
 - Clustering language-specific types
- Summarization
- 5 A web application and partial implementation in R

(IJP PAN) ParaViz 11 / 49

- Comparing functional domains on the basis of a parallel corpus
 - ParaSol: A Parallel Corpus of Slavic and other Languages
- Operationalization and query
 - An example: cognate prepositions
 - Operationalization
 - Evaluation: corpus examples
- 3 Visualisation
 - Visualising single classes
 - Clustering Classes
 - Clustering language-specific types
- Summarization
- 5 A web application and partial implementation in R

(IJP PAN) ParaViz 12 / 49

Prepositions: K 'to', DO 'to', V 'in(to)'

```
(1)
         'Ivan [...] could not help himself and, on seeing the water gush into
         the tub in a wide stream from the gleaming faucet, said ironically:'
         Иван [...] не удержался и, видя, как вода хлещет в ванну широкой
    ru
         струей из сияющего крана, сказал с иронией:
    by
         ... шырокім струменем прэ ў ванну вада ...
    uk
         ... як вода рине у ванну широким струменем ...
        ... як вода плеще до ванни широким струменем ...
         ... obserwując wodę [...] lejącą się [...] do wanny ...
    pl
         ...woda szeroko chlusta ze lśniącego kranu do wanny ...
         ... který se řinul z nablýskaného kohoutku do vany ...
    C7
    sk
         ... širokým prúdom tečie do vane voda ...
         ...kako se voda v širokem curku zliva [...] v kad ...
    sl
    hr
         ...iz blistave pipe voda u širokoj struji teče u kadu ...
    sr
         ...voda juri u kadu širokim mlazom iz blistave slavine ...
         ...kako se voda iz blistave slavine [...] izliva u kadu ...
    sra
    bg
         ...как водата плющи във ваната на широка струя ...
```

Prepositions: K 'to', DO 'to', V 'in(to)'

- (2) 'Aphranius bowed, moved the chair closer to the bed, and sat down'
 - ru Афраний поклонился, пододвинул кресло поближе к кровати и сел
 - by Афраній пакланіўся, падсунуў крэсла бліжэй да ложа і сеў
 - uka Афраній вклонився, підсунув крісло ближче до ліжка й сів
 - uk Афраній уклонився, підсунув крісло ближче до ложа і сів
 - pla Afraniusz skłonił się, przysunął fotel ku posłaniu i usiadł [...].
 - pl Afraniusz skłonił się, przysunął tron **bliżej łoża** i usiadł [...].
 - cz Afranius se uklonil, přisunul křeslo blíž k lůžku a usedl [...].
 - sk Afránius sa uklonil, pritiahol si kreslo bližšie k lôžku a sadol si
 - sl Afranij se je priklonil, pomaknil naslanjač bliže k postelji in sedel
 - hr Afranije se poklonio, pritegao naslonjač bliže **krevetu** i sjeo [...].
 - sr Afranije se pokloni, primače fotelju bliže $\mathbf{krevetu}$ i sede $[\dots]$.
 - mk Афраниј се поклони, ја намести фотелјата поблиску до креветот и седна
 - bg Афраний се поклони, премести креслото си по-близо до ложето и седна

Prepositions: K 'to', DO 'to', V 'in(to)'

```
(3)
        'Styopa brought the glass to his lips'
        К Прыгающей рукой поднес Степа стопку к устам, [...].
    ru
        D Дрыжачай рукою паднёс Сцёпа гарэлку да вуснаў, [...].
        D Непевною рукою підніс Стьопа до вуст чарку, [...].
        D Тремтячою рукою підніс Стьопа стопку до вуст, [...].
        D Drżącą ręką Stiopa podniósł kieliszek do ust, [...].
        D Stiopa podniósł rozdygotaną ręką szklaneczkę do ust, [...].
        K Lotrov rozechvělou rukou pozvedl sklenici k ústům [...].
        K Stopa roztrasenou rukou zdvihol k ústam pohárik [...].
   sk
   sl
        K S tresočo se roko je Stjopa ponesel kozarec k ustom, [...].
    hr
        - Stjopa je drhtavom rukom prinio čašicu ustima, [...].
        - Drhtavom rukom Stjopa prinese čašicu ustima, [...].
   sr
        D Со растреперена рака Стјопа ја доближи чашата до уста
   sra
    bg
        К Стьопа поднесе с трепереща ръка чашата към устата си
```

(IJP PAN) ParaViz 15 / 49

- Comparing functional domains on the basis of a parallel corpus
 - ParaSol: A Parallel Corpus of Slavic and other Languages
- Operationalization and query
 - An example: cognate prepositions
 - Operationalization
 - Evaluation: corpus examples
- Wisualisation
 - Visualising single classes
 - Clustering Classes
 - Clustering language-specific types
- Summarization
- 5 A web application and partial implementation in R

Word aligned corpus

```
<w id="7.7" lem="жаркий" pos="Afpmsg">жаркого<waligns>
      <walian lna="ba">
         <w id="8.9" lem="горещ" pos="A---:sm0">горещ</w>
      </walign>
      <walign lng="bv">
         <w id="7.5" lem="надзвычай" pos="ADV.norm">надзвычай</w>
         <w id="7.6" lem="душны" pos="A,norm,nom,sq,m:A,norm,acc,sq,m,inan">душны</w>
      </walign>
      <walian lng="cz">
         <w id="4.2" lem="dusn\u00f3" pos="AAIS6----1A----">dusn\u00e9m</w>
         <w id="4.3" lem="jarni" pos="AAIS6----1A----">jarnim</w>
      </walign>
      <walian lng="hr">
         <w id="7.7" lem="neobičan" pos="Rnp">neobično</w>
         <w id="7.8" lem="topal" pos="Afpmsqy">toplog</w>
      </walign>
      <walian lna="mk">
         <w id="2.5" lem="пролетен" pos="A">пролетно</w>
      </walign>
      <walign lng="pl">
         <w id="3.5" lem="wiosennv" pos="adi:sa:nom:n:pos">wiosenne</w>
      </walian>
      <walign lng="pla">
         <w id="8.8" lem="upalny" pos="adj:sg:gen:m3:pos">upalnego</w>
      </walian>
      <walian lng="sk">
         <w id="6.1" lem="teplý" pos="Afpnsn">Teplé</w>
      </walign>
```

Parameter file: V

```
<type id="V" name="V">
        <criteria><lnq>ru</lnq><reqexp level="preclem">^Bo?$</reqexp> <reqexp level="ta"</pre>
        <criteria><lng>uk</lng><reqexp level="preclem">^[By]$</reqexp><reqexp level="ta"</pre>
        <criteria><lng>by</lng><regexp level="preclem">^[yỹ]$</regexp><regexp level="ta"</pre>
        <criteria><lng>mk</lng><reqexp level="preclem">^Bo?$</reqexp> <reqexp level="t</pre>
        <criteria><lng>bg</lng><regexp level="preclem">^вь?в?$</regexp> <regexp level="
        <criteria><lng>pl</lng><reqexp level="preclem">^we?$</reqexp> <reqexp level="ta"</pre>
        <criteria><lng>cz</lng><regexp level="preclem">^ve?(-\d)?$</regexp> <regexp lev</pre>
        <criteria><lng>sk</lng><regexp level="preclem">^vo?$</regexp> <regexp level="ta"</pre>
        <criteria><lng>sl</lng><regexp level="preclem">^v$</regexp> <regexp level="ta"</pre>
        <criteria><lnq>hr</lnq><regexp level="preclem">^u$</regexp> <regexp level="ta"</pre>
        <criteria><lng>sr</lng><regexp level="preclem">^u$</regexp>
                                                                          <regexp level="ta
        <criteria><lng>de</lng><regexp level="preclem">^(in|im)s?$</regexp><regexp level="preclem">
        <criteria><lng>lt</lng><reqexp level="preclem">^i$</reqexp><reqexp level="tag">
        <criteria><lng>us</lng><regexp level="precword">^[Ww]e?$</regexp> </criteria>
</type>
```

levels: token, lemma, tag; nontoken, nonlemma, nontag for actual and 2 preceding corpus positions

(IJP PAN) ParaViz 18 / 49

Parameter file: V with case

```
<type id="V" name="V">
 <criteria><lng>mk</lng><regexp level="preclem">^Bo?$</regexp> <regexp level="tag">^[Nn].*</regexp>
                                                                                                     </criteria>
 <criteria><lng>bg</lng><redexp level="preclem">>Bb?B?$</redexp> <regexp level="tag">^N.*</redexp>
                                                                                                   </criteria>
 <criteria><lng>de</lng><regexp level="preclem">^(inlim)s?$</regexp><regexp level="tag">^NN$</regexp>
                                                                                                     </criteria>
 <criteria><lng>us</lng><regexp level="precword">^[Ww]e?$</regexp>
</type>
<type id="v" name="VACC">
 </criteria>
 <criteria><lng>uk</lng><redexp level="breclem">^[BV]$</regexp><redexp level="tag">^S.*(accigen)..*</regexp>
                                                                                                            </crite
 <criteria><lng>by</lng><regexp level="preclem">^[yy]$</regexp><regexp level="tag">^S.*(acc|gen),.*</regexp>
                                                                                                            </crite
 <criteria><lng>pl</lng><redexp level="preclem">^we?$</redexp> <redexp level="tag">^subst.*(genlacc).*</redexp></criteria>
 <criteria><lng>cz</lng><reqexp level="preclem">^ve?(-\d)?$</reqexp> <reqexp level="tag">^N...(2|4).*</reqexp>
                                                                                                              </cri
 <criteria><lng>sk</lng><regexp level="preclem">^vo?$</regexp level="tag">^N...[ga].*</regexp>
                                                                                                       </criteria>
 <criteria><lng>sl</lng><regexp level="preclem">^v$</regexp>
                                                             <regexp level="tag">^S...[rt].*</regexp>
                                                                                                       </criteria>
 <criteria><lng>hr</lng><regexp level="preclem">^u$</regexp>
                                                             <regexp level="tag">^N...[ga].*</regexp>
                                                                                                       </criteria>
 <criteria><lng>sr</lng><regexp level="preclem">^u$</regexp>
                                                             <regexp level="tag">^N...[ga].*</regexp>
                                                                                                       </criteria>
</type>
<type id="w" name="VLOC">
 <criteria><lng>ru</lng><reqexp level="preclem">^Bo?$</reqexp < regexp level="tag">^N...[dl].*</reqexp>
                                                                                                       </criteria>
 <criteria><lng>uk</lng><redexp level="preclem">^[BV]$</redexp><redexp level="tag">^S.*(dat|loc),.*</redexp>
                                                                                                            </crite
 <criteria><lng>by</lng><regexp level="preclem">^[yy]$</regexp><regexp level="tag">^S.*(dat|loc),.*</regexp>
                                                                                                            </crite
 <criteria><lnq>pl</lnq><regexp level="preclem">^we?$</regexp> <regexp level="taq">^subst.*(dat|loc).*</regexp></criteria>
 <criteria><lng>cz</lng><regexp level="breclem">^ve?(-\d)?$</regexp> <regexp level="tag">^N...(3|6).*</regexp>
                                                                                                              </cri
 <criteria><lng>sk</lng><regexp level="preclem">^vo?$</regexp level="tag">^N...[dl].*</regexp>
                                                                                                       </criteria>
 <criteria><lng>sl</lng><regexp level="preclem">^v$</regexp>
                                                             <regexp level="tag">^S...[dml.*</regexp>
                                                                                                       </criteria>
 <criteria><lng>hr</lng><regexp level="preclem">^u$</regexp>
                                                             <regexp level="tag">^N...[dl].*</regexp>
                                                                                                       </criteria>
 <criteria><lng>sr</lng><regexp level="preclem">^u$</regexp>
                                                             <regexp level="tag">^N...[dl].*</regexp>
                                                                                                       </criteria>
</type>
```

4 D > 4 A > 4 B > 4 B >

- Comparing functional domains on the basis of a parallel corpus
 - ParaSol: A Parallel Corpus of Slavic and other Languages
- Operationalization and query
 - An example: cognate prepositions
 - Operationalization
 - Evaluation: corpus examples
- Wisualisation
 - Visualising single classes
 - Clustering Classes
 - Clustering language-specific types
- Summarization
- 5 A web application and partial implementation in R

(IJP PAN) ParaViz 20 / 49

Color-coded corpus samples

Query interface

Search

Instructions: choose primary and aligned language(s), and enter a query. You need to define a query for the primary language (in red). In addition, you may define queries on the aligned languages, which will restrict outout accordingly.



old concordancer

Export XML



- Based on ParaVoz https://bitbucket.org/rvwfels/paravoz, interface to CWB-encoded parallel corpus,
- CWB output transformed to XML, XSLT for classification of result XML

Color-coded corpus samples

		powieścią . Zaczął em na przykład bać się ciemności .								
54763 Но никто не шел .	Але ніхто не йшов	Ale nikt nie przychodził .	Nikt jednak nie nadchodził .	Ale nikdo nepřicházel .	Ale nik neprichádzai .	Vendar nihče ni prišel .	Ali nitko nije dolazlo .	Ali niko nije dolazlo	Ali nije dolazlo niko .	Но никој не дојде
59226 Он понимал , что пришла его гибель .	Він розумів , що прийшла його погибель .	Wiedział , że nadeszła jego zguba .	Wiedział , że nadeszla jego ostatnia chwila .	Bylo mu jasné , že to znamená jeho konec .	Uvedomil si , že nastal jeho koniec .	Razumel je , da je prišla njegova pogibel .	Shvatio je da je stigla njegova propast .	Shvatio je da mu je to kraj .	Shvatao je da mu Je došao kraj .	Тој сфати дека му доаѓа крајот .
подошла кентурия	орудою Марка	Wreszcie nadeszla centuria pod dowództwem Marka Szczurobójcy.	Wreszcie nadeszła centuria dowodzona przez Marka Szczurzą Śmierć.	Nakonec připochodovala centurie pod velením Marka Krysobijce .	Naostatok prišia do cieľa centúria pod velením Marka Potkanobijcu .	Naposled Je prišla še centurija pod poveljstvom Ma Podganarja .	Konačno je prispjela centurija k d apovjedništvom Marka Štakoraša.	Poslednja stiže centurija pod komandom Marka Pacolovca .	Najzad Je prispela I centurija pod komandom Marka Pacomora .	Најпосле дојде центуријата под команда на Марв Стаорцоубиецот
80482 На тихий и жалобиый крик прифессора прибежала Ксения Никитишна и совершение от совершение от колечно, кто - нибудь из тациентов подбросни котения, что это нередко бывает у профессоров.	надбігла Ксенія Микитівна і цілком його заспокоїла, відразу сказавши, що це, безперечно , хтось із пацієнтів підкинув кошеня,	uspokoiła go zupełnie powiedziawszy , że	okrzyk profesora przy bległa Ksenia Nikitiszna i z miejsca uspokoiła go zapewniając, że to któryś z pacjentów musiał podrzucić kotka, co się często przydarza	Na jeho přidušený výkřík přitěhla Xenie Nikitična a pohotově ho uklidnila sdělením, že se profesorům často stává, že některý pacient jim tajně podstrčí kotě.	dokonale upokojila , povedala , že to iste niektorý pacient podhodil mača , to sa	Na profesorjev tihi in žalostni krik je prititela Ksenija Nikitišna in ga takoj popolnoma pomirila , rekoč , da je mačko seveda podtaknil kateri izmed bolnikov , to da se profesorjem neredko dogaja .	od pacijenata podmetnuo mače i	Na tih i žalostiv povik profesora dotrča Ksenija Nikitišna i odmah ga smiri, rekavši mu da je to sigumo neko od pacijenata podmetnuo mače, što se inače često dešava profesorima.	Na tihi i žalosni profesorov krik dotrča Ksenija Nikitišna i vrio brzo ga umiri rekavši da je to , naravno neko od pacijenata poturio mačence , da se to često dešava i kod drugih profesora .	сосема го успоко објаснувајќи му д сигурно некој од нациентите му го оставил мачето и
81170 Что дальше происходилю диковинного в Москве в эту ночь мы не знаем и дооксмваться , конечно не станем , тем более, что настает пора переходить нам ко второй части уготого правдивого повествования.	частину цісї правдивої оповіді .	bardziej , że czas nam już przejść do drugiej części naszej prawdziwej	Moskwie tej nocy , i oczywiście nie zamierzamy tego dociekać , tym bardziej że czas już , aby śmy przeszli do drugiej części tej jakże prawdziwej opowieści .	jaké další záhady se odehrály té noci v Moskvě, a nehodláme po nich pátrat tím spíš, že je na čase přejít k druhé části našeho	Aké nevídané veci sa diali tej noci v Moskve, to nevieme a, prirodzene, nebudeme po tom pátrať – tým skôr, že je už načase prejsť k druhej časti nášho pravdivého rozprávania.	Moskvi še zgodilo nenavadnega , tega ne vemo in seveda tudi ne bomo šli raziskovat — toliko manj , ker Je prišel čas , da preidemo k drugemu delu te	dešavalo u Moskvi te noći, ne znamo i dakako nećemo ni istraživati, – to više	dešavalo , mi ne znamo i , razume se , nećemo ni da istražujemo - utoliko pre , što je došlo vreme da pređemo na drugi deo naše	Sta se sve dalje čudnovato odigravalo u Moskvi te noći , ne znamo i , naravno , nećemo nastojati da dokućimo - tim pre što dolazi vreme da pređemo na drugi deo ove istinite pripovesti .	настојуваме да разбереме , - до толку повеќе што
85846 Вам ни о нем не придется заботиться , вас доставят куда нужно , и вам не причинят никакого беспокойства .	Вам нічим не доведеться сущити голову , вас допровадять куди слід , і вам не завдадуть ніякого клопоту .	Nie musi się pani o nle martwić; zostanie pani dostarczona gdzie trzeba bez żadnej subiekcji.	Zostanie pani dostarczona na miejsce bez żadnych kłopotów i o nic nie będzie się pani musiała troszczyć.	Nemusite se o nic starat, dopravi vás až na místo a nezpůsobí vám to nejmenší obtiže.	Nemusíte sa o nič starať, dopravia vás na miesto, nebudete s tým mať nijaké ťažkosti.	Za nič vam ni treba skrbeti , spravili vas bodo tja , kamor bo potrebno , in nihče vas ne bo nadlegoval .	čemu brinuti , vas će dopratiti kamo treba i neće vam	Nećete morati ni za šta da brinete, odvešće vas kud treba, i neće vas ničim uznemiravati.	Vi ne morate ni o čemu da brinete , bićete dovedeni kuda treba i niko vam neće učiniti ništa nažao .	Не треба да се грижите за ништо ќе бидете доведе каде што треба и никој нема да ве вознемирува .
		— Ścisnęła				« Stisnila je s				

- Comparing functional domains on the basis of a parallel corpus
 - ParaSol: A Parallel Corpus of Slavic and other Languages
- Operationalization and query
 - An example: cognate prepositions
 - Operationalization
 - Evaluation: corpus examples
- Visualisation
 - Visualising single classes
 - Clustering Classes
 - Clustering language-specific types
- Summarization
- 5 A web application and partial implementation in R

(IJP PAN) ParaViz 23 / 49

'Russian'

'Belarusian'

'Russian'

distances: for each pair, take proportion of differing symbols

(IJP PAN) ParaViz 24 / 49

distances: for each pair, take proportion of differing symbols

```
'Russian' pipippip
'Polish' pipipppi
'Czech' ipiiiipi
```

distances: for each pair, take proportion of differing symbols

```
'Russian' pipippip
'Polish' pipipppi
'Czech' ipiiiipí
```

RU-PL: 2/9 = 0.222

(IJP PAN) ParaViz 24 / 49

distances: for each pair, take proportion of differing symbols

```
'Russian' pipippip
'Polish' pipipppi
'Czech' ipiiiipi
```

RU-PL: 2/9 =0.222 PL-CZ: 5/9 =0.555

distances: for each pair, take proportion of differing symbols

```
'Russian' pipippip
'Polish' pipipppi
'Czech' ipiiiipi
```

RU-PL: 2/9 =0.222 PL-CZ: 5/9 =0.555 CZ-RU: 7/9 =0.777

Matrix with binary values

of distances:

- [1] 'Russian' 0.0 0.36231884 0.75 0.67741936 0.328125 0.45454547 0.1 [2] 'Polish' 0.36231884 0.0 0.61764705 0.5645161 0.359375 0.4090909 [3] 'Czech' 0.75 0.61764705 0.0 0.45901638 0.52380955 0.41538462 0
- [3] 'Czech' 0.75 0.61764705 0.0 0.45901638 0.52380955 0.41538462 0
- [5] 'Bulgarian' 0.328125 0.359375 0.52380955 0.5254237 0.0 0.33333334 [6] 'Croatian' 0.45454547 0.4090909 0.41538462 0.2542373 0.33333334 0
- [7] 'Belarusian' 0.14925373 0.26865673 0.7121212 0.55737704 0.3125 0.40

Operationalization

- Use XSLT scripts on the raw corpus data for classification
- based on word alignment, starting with a primary language
- filter tokens in primary language to modify the question

```
MATRIX
'Bulgarian'
       -b---z-aa--aanan------b-dbp
'Belarusian'
       -z---o----a----zz----b-----b--bb--zd-----bnn-------p--
'Czech'
       -----yyyyyy-n----d-----z----zz-----bb--r-d-----y-
'Croatian'
       -b---ii-rrr-----d--dd-b
'Macedonian'
       ------b----ba-aa-----bdbb
       y---nn-----nb------yobb-----y-z----y-b-b----r---r--
'Polish'
'Russian'
       -----o-bbaaa-----b-----b-----b-----b---aaa----y----b
'Slovak'
       -o-b----y-aay-----a---zz-a-y----z-z---b--a---b--a---b---a---p-
       'Slovenian'
'Serbian'
       b----i---rr----z---z---zd-----zd-----b-----b----i---pd--
'Ukrainian'
```

Operationalization

- Use XSLT scripts on the raw corpus data for classification
- based on word alignment, starting with a primary language
- filter tokens in primary language to modify the question

```
MATRIX
'Bulgarian'
       -b---z-aa--aanan------b-dbp
'Belarusian'
       -z---o----a----zz----b-----b--bb--zd-----bnn-------p--
'Czech'
       -----yyyyy-n----d-----z---zz-----bb--r-d-----y-
'Croatian'
       -b---ii-rrr-----d--dd-b
'Macedonian'
       ------b----ba-aa-----bdbb
       y---nn-----nb------yobb-----y-z----y-b-b----r---r--
'Polish'
'Russian'
       -----o-bbaaa-----b-----b-----b-----b---aaa----y----b
'Slovak'
       -o-b----y-aay-----a---zz-a-y----z-z---b--a---b--a---b---a---p-
       'Slovenian'
'Serbian'
       b----i---rr----z---z---zd-----zd-----b-----b----i---pd--
'Ukrainian'
```

Filter results, calculate Hamming distances, visualize in SplitsTree


- Comparing functional domains on the basis of a parallel corpus
 - ParaSol: A Parallel Corpus of Slavic and other Languages
- Operationalization and query
 - An example: cognate prepositions
 - Operationalization
 - Evaluation: corpus examples
- Visualisation
 - Visualising single classes
 - Clustering Classes
 - Clustering language-specific types
- Summarization
- 5 A web application and partial implementation in R

(IJP PAN) ParaViz 27 / 49

Visualization of single class: DO, Bulgakov



Unmasking: remove UK and UKA from Bulgakov



Unmasking: remove BY and UK from Bulgakov



Visualization: DO, Potter




Outline

- Comparing functional domains on the basis of a parallel corpus
 - ParaSol: A Parallel Corpus of Slavic and other Languages
- Operationalization and query
 - An example: cognate prepositions
 - Operationalization
 - Evaluation: corpus examples
- Visualisation
 - Visualising single classes
 - Clustering Classes
 - Clustering language-specific types
- Summarization
- 5 A web application and partial implementation in R

(IJP PAN) ParaViz 32 / 49

Preposition types by similarity in context




(IJP PAN)

ParaViz

33 / 49


Preposition types by similarity in context




Outline

- Comparing functional domains on the basis of a parallel corpus
 - ParaSol: A Parallel Corpus of Slavic and other Languages
- Operationalization and query
 - An example: cognate prepositions
 - Operationalization
 - Evaluation: corpus examples
- Visualisation
 - Visualising single classes
 - Clustering Classes
 - Clustering language-specific types
- Summarization
- 5 A web application and partial implementation in R

Prepositions by similarity in context: LEM




Prepositions by similarity in context: BULGAKOV




(IJP PAN) ParaViz 36 / 49

OSTROVSKIJ, with case




(IJP PAN) ParaViz 37 / 49

Bulgakov, only K, KON, DO and V(acc)



Bulgakov, only K, KON and DO



Outline

- Comparing functional domains on the basis of a parallel corpus
 - ParaSol: A Parallel Corpus of Slavic and other Languages
- Operationalization and query
 - An example: cognate prepositions
 - Operationalization
 - Evaluation: corpus examples
- Wisualisation
 - Visualising single classes
 - Clustering Classes
 - Clustering language-specific types
- 4 Summarization
- 5 A web application and partial implementation in R

verbs equivalent to Russian PRI:

			==PRI:=====				=		
++ru:++ ==>PRI:	++by:++ ==>PRI:	++uk:++ ==>PRI:	++uka:++ ==>PRI:	++pl:++	++pla:++	++cz:++	++sk:++	++sl:++	++hr:++
прийти (66),	прыйсці (53), прыехаць (20),	прийти (43), приїхати	прийти (51), приїхати (16), принести (16),	==>PRI:	>PRI:	==>PRI:	>PRI:	==>PRI:	>PRI:
приходить (52),	прынесці (16), прыходзіць	(17), принести (12),	приходити (11), привести (9), прислати	przyjść (38),	przyjść (43),	přijít (30),	prist' (57),	priti (71),	priznati (1
прийтись (48),	(12), прывезці (9), прызнацца	приходити (9), привезти	(8), привезти (7), прилетіти (7), присісти	przyjechać	przybyć (11),	přijet (18),	priznať (11),	priznati (18),	približiti
приказать (29),	(8), прыслухацца (8),	(8), прийти:прийшлий	(6), присідати (6), припасти (6), прийняти	(17), przyznać	przynieść (9),	přihnat (7),	prijať (9),	pripeljati	(15),
принимать (28),	прытуліць (7), прыпасці (7),	(7), привести (7),	(б), притулитися (б), приїжджати (5),	(9), przynieść	przyjąć (9),	přitisknout	pritisnúť (9),	(15),	približavat
принять (21),	прысесці (6), прытварацца	прислати (7), припасти	прислухатися (5), приснитися (5),	(9), przyjąć (9),	przylgnąć (9),	(7), přiznat	priblížiť (7),	približati	(10), prim
приходиться (18),	(б), прыязджаць (б),	(6), прикидатися (5),	прилаштувати (5), прикласти (4),	przywieźć (7),	przyznać (5),	(6), přinést	pridať (6),	(15), prinesti	(9), pripad
прибавить (18),	прыляцець (6), прывыкнуць	прилетіти (5), прикласти	прикипіти (4), примружитися (3),	przyśnić (7),	przywieźć (4),	(6), přijmout	priložiť (6),	(14),	(8), prispje
приглашать (16),	(5), прывесці (5), прытуліцца	(5), приїздити (4),	прикидатися (3), приняти:прийняти (3),	przychodzić	przywyknąć	(6), přivézt	prižmúriť (5),	prihajati	(5), privuć
принести (16),	(5), прыўстаць (4), прыняць	прибрати (4),	прибрати (3), приймати (3), прилягти (3),	(6), przysłać	(4),	(5), přidat	neprísť (4),	(14),	(5),
привести (13),	(4), прымаць (4), прыслаць	прислухатися (4),	пританцьовувати (3), прикластися (3),	(5), przyjeżdżać	przychodzić	(5), připojit	priniest' (4),	pristaviti (7),	pripremiti
приезжать (12),	(4), прыслухоўвацца (4),	прилучитися (4),	привернути (2), привертати (2),	(4),	(4),	(4),	pricestovať	prileteti (7),	(5), priljub
приехать (12),	прысядаць (4),	присідати (4), прикипіти	причепитися (2), придумати (2),	przygotować	przykładać	přimhouřit	(4), pripojiť	pridružiti	(5),
пригласить (11),	прытанцоўваць (4), прызнаць	(4), пританцьовувати (4),	пригадати (2), припадати (2), притискати	(4), przypaść	(4), przyłączyć	(3), přivést	(4), priviest'	(7),	prisluškiva
признаваться (9),	(3), прымешвацца (3),	причепитися (3),	(2), приєднатися (2), прислухаючисити	(4), przyłożyć	(4),	(3), přiblížit	(3), prihnať	privzdigniti	(4),
приближать (9),	прыйсці:прыйсце (3),	приготувати (3),	(2), притихнути (2), приставати (1),	(4), przytulić	przyjeżdżać	(3),	(3), nepriniest'	(6),	prisustvov
принадлежать (9),	прысутнічаць (3), прылегчы	приєднатися (3),	прищулитися (1), приглушити (1),	(4),	(3), przyjechać	přitáhnout	(3), prisnit'	pripotovati	(4), pričinj
признавать (8),	(3), прыбегчы (3),	прийняти (3),	призвести (1), прищулити (1),	przyzwyczaić	(3),	(2),	(3),	(5), pritisniti	(4), prihva
		приснитися (3),	приготувати (1), прикривати (1),	(3), przybyć	przygotować	přiznávat	prit'ahovat'		(4),
(8), приближаться	(2), прыдумаць (2),	припасти:припалий (3),	прикрити (1), пригостити (1),	(3), przybrać	(3), przyłożyć	(2),	(2),	prisluškovati	priključiti
(8),	прызнацца:прызнавацца (2),	притиснутися (3),	примружувати (1), притримати (1),	(3), przyłączyć	(3), przyśnić	přiběhnout	neprichádzať	(4), pripreti	(4),
прищуриваться	прыйшоўшы (2), прыкрываць	привертати (2),	пристати (1), прилучитися (1),	(3), przydarzyć		(2),	(2), pripravit'	(3),	pridružiti
(8),		примружитися (2),		(2), przykuć		přicházet			(4), pripiti
прислушиваться	прытварыцца (2), прыліць	прискалити (2), присісти	пришити (1), притягти (1), приволочити	(2), przykucnąć	(3), przysłać	(2),	(2), pritískať	(3),	(4), privlai
(8), привезти (7),	(2), прыдзірацца (2),	(2), придумати (2),	(1), пришпилити (1),	(2),	(3), przyciągać	přistoupit	(2), priletiet'	prisluhniti	(3),
присаживаться	прывалачы (2), прывітаць (2),	, прибути:прибулий (2),	пристанути:пристати:пристав:приставити	przyśpieszyć	(2),	(2), přiletět	(2), privalit'	(3), pripetiti	priznavati
(7), приводить (7),	прыцэліцца (2), прыкіпець	прикривати (2),	(1), пригадувати (1), пригадатися (1),	(2),	przykucnąć	(2), přiložit	(1), priviezt'	(2), prijeti	(3),
притворяться (7),	(2), прыціскацца (2),	приносити (2),	привітати (1), привітатися (1), прибігти	przyprowadzić	(2), przysiadać	(2),	(1), prisadnúť	(2),	prikrivati
присниться (7),	прыцягнуты (1), прызнаваць	приняти:прийняти (2),	притуляти (1), прикотити (1),	(2), przyznawać			pripliest	pripravljati	(3), pričin
приблизиться (7),	(1), прызнаць:прызнаваць (1),			(2), przymrużać			(1), privádzať		(3), prima
				(2), przywiązać		(1), přihodit		približevati	
				(2), przymrużyć		přilepit		(2), pripadati	
(б), прикрывать	прызнавацца (1),	(2), привабити (2),	присисати (1), привалитися (1),	(2),	(2), przylecieć	(1),	(1), pridávať	(2), privleči	(3), prisjet

verbs equivalent to Russian PRI: zoom in

```
++ru:++ ==>PRI:
прийти (66),
приходить (52),
прийтись (48),
приказать (29),
принимать (28),
принять (21),
приходиться (18),
прибавить (18),
приглашать (16),
принести (16),
привести (13),
приезжать (12),
```

```
++cz:++
              ++sk:++
==>PRI:
              ==>PRI:
přijít (30),
              prísť (57),
přijet (18),
              priznať (11),
přihnat (7),
              prijať (9),
přitisknout
              pritisnúť (9),
(7), přiznat
              priblížiť (7),
(6), přinést
              pridať (6),
(6), přijmout priložiť (6),
(6), přivézt
              prižmúriť (5),
(5), přidat
              neprísť (4),
(5), připojit
              priniesť (4),
(4),
              pricestovať
```

```
++sl:++
              ++hr:++
==>PRI:
              ==>PRI:
priti (71),
              priznati (16),
priznati (18), približiti
pripeljati
              (15),
(15),
              približavati
približati
              (10), primiti
(15), prinesti (9), pripadati
              (8), prispjeti
(14),
prihajati
              (5), privući
(14),
              (5),
pristaviti (7), pripremiti
prileteti (7), (5), priljubiti
```

Outline

- Comparing functional domains on the basis of a parallel corpus
 - ParaSol: A Parallel Corpus of Slavic and other Languages
- Operationalization and query
 - An example: cognate prepositions
 - Operationalization
 - Evaluation: corpus examples
- Wisualisation
 - Visualising single classes
 - Clustering Classes
 - Clustering language-specific types
- 4 Summarization
- 5 A web application and partial implementation in R

A web based application

Computations (so far) done using R, Perl-scripts, XSLT, OpenCWB, SplitsTree

Projected web interface:

- Using AngularJ, Django, Python, MySQL
- An asynchronous interface: users log on and manage their data and evaluations
- Two types of user data:
 - environment data: parameter files, default options
 - evaluations: individual runs of parameter files with different options and their results
- Results: Colour-coded corpus samples; zip-files with network and distance data, ready visualizations and word lists

(IJP PAN) ParaViz 44 / 49

A web based application

Computations (so far) done using R, Perl-scripts, XSLT, OpenCWB, SplitsTree

Projected web interface:

- Using AngularJ, Django, Python, MySQL
- An asynchronous interface: users log on and manage their data and evaluations
- Two types of user data:
 - environment data: parameter files, default options
 - evaluations: individual runs of parameter files with different options and their results
- Results: Colour-coded corpus samples; zip-files with network and distance data, ready visualizations and word lists
- ...comments very much appreciated!


(IJP PAN) ParaViz 44 / 49

Possible and actual implementation in R

Visualization

- Step one: categorization of the corpus data in XSLT so far -> can be replaced by R
 - access corpus data with rcqp (interface to CorpusWorkBench)
 - query primary language to get corpus positions; extract relevant word forms from word alignment/sentence alignment into a table object
 - apply classification to each cell to derive a table of classifications
- Step two: filter the table to restrict it to certain features so far done in Perl, elementary in R
- Step three: derive various distance matrices built-in in SplitsTree -> basically already implemented in R (see separate slide)
- Step four: visualize as NeighborNet
 -> implemented in R in phangorn package, but not very nice graphics

Phangorn Neighbornet:



Possible and actual implementation in R

Corpus examples

- Step one: query corpus data with rcqp
- Step two: apply xslt stylesheet for color coding

... not quick and not elegant

(IJP PAN) ParaViz 47 / 49

Summary

- A query system to query a multilingual parallel corpus
- Focus on analyzing functional domains reflected in distributions
- Individual data points and aggregations
- Projected: web-based system for registered user

(IJP PAN) ParaViz 48 / 49

Thank you

Dziękuję!

www.parasolcorpus.org ruprecht.waldenfels@gmail.com

This research is supported by the Swiss National Science Foundation

(IJP PAN) ParaViz 49 / 49